Classificação de Gêneros Musicais Brasileiros com PLN

Relatório Final de Projeto

Disciplina: Processamento de Linguagem Natural

Alunos:
Adriano Dias Jerônimo Filho
Davi Henrique Teixeira de Barros
Pedro Caio Alonço
Rhonnye Wendell Lourenço Soares Martins

João Pessoa, 2025

1. Apresentação do Problema

A música brasileira é reconhecida mundialmente por sua diversidade e riqueza de gêneros. Gêneros como samba, forró, sertanejo, MPB, gospel, funk e rap apresentam características culturais e linguísticas distintas que se refletem diretamente nas letras de suas músicas. Essa pluralidade torna o corpus musical brasileiro um terreno fértil para a aplicação de técnicas de Processamento de Linguagem Natural (PLN).

O problema abordado neste projeto é a classificação automática do gênero musical de uma canção a partir de sua letra, formulado como um problema de classificação multi-rótulo, uma vez que uma mesma música pode pertencer a mais de um gênero simultaneamente. Por exemplo, uma canção pode ser classificada como sertanejo e romântico ao mesmo tempo.

A principal dificuldade reside no fato de que gêneros musicais frequentemente se sobrepõem semanticamente — um artista de MPB pode fazer uso de vocabulário romântico, e o samba pode apresentar temáticas religiosas, o que torna a fronteira entre classes naturalmente imprecisa. Além disso, o desbalanceamento entre gêneros representa um desafio adicional significativo para os modelos de aprendizado de máquina.

2. Objetivos

Os objetivos gerais do projeto são:

- Construir um sistema de classificação multi-rótulo de gêneros musicais brasileiros baseado nas letras das músicas.
- Comparar o desempenho de quatro modelos de aprendizado de máquina clássicos: Regressão Logística com TF-IDF, Naive Bayes com TF-IDF, Random Forest com TF-IDF e Word2Vec com Regressão Logística.
- Avaliar o impacto do número de classes-alvo no desempenho dos modelos, comparando duas abordagens: classificação com 11 gêneros e classificação restrita aos 5 gêneros com melhor desempenho inicial.
- Aplicar o modelo de linguagem BERTimbau para classificação dos Top 5 gêneros e comparar seus resultados com os modelos clássicos.

3. Dados Utilizados e Pré-processamento

3.1. Fontes de Dados

O dataset utilizado é composto por duas fontes integradas: uma base de artistas (artists-data.csv) contendo informações sobre artistas. Incluindo nome, gêneros musicais declarados, popularidade e link identificador, além de uma base de letras (lyrics-data.csv) com o conteúdo textual das músicas, seus títulos e identificadores de artista. As duas bases foram unidas por meio de uma chave de link, gerando um dataset consolidado com artista, letra, idioma, popularidade e gênero.

A base de artistas original continha 4.168 artistas e 79 gêneros distintos. A base de letras continha 379.930 registros. Após a junção e os filtros descritos a seguir, o corpus utilizado foi reduzido para 43.907 músicas em português com rótulos de gênero válidos.

3.2. Filtragem e Limpeza

O pré-processamento dos dados envolveu as seguintes etapas:

- Filtragem por idioma: mantidas apenas as letras em português (language == 'pt').
- Remoção de artistas com poucos registros: artistas com menos de 30 músicas foram removidos para garantir representatividade estatística.
- Filtragem por popularidade: músicas de artistas com popularidade igual a zero foram descartadas.
- Remoção de nulos: linhas sem artista, gênero ou popularidade foram eliminadas.
- Enriquecimento dos gêneros via API: a coluna de gênero original (baseada nos gêneros declarados dos artistas) foi enriquecida utilizando a API do Last.fm, que retorna tags associadas a cada faixa. Essa nova coluna (Genres_Updated) passou por uma whitelist de gêneros válidos.
- Remoção de músicas sem gênero identificado: músicas que não obtiveram correspondência na whitelist foram descartadas.

3.3. Consolidação dos Gêneros

Os rótulos obtidos via API apresentavam variações (por exemplo: 'forró', 'forro', 'xote', 'baião' foram todos mapeados para 'forró'). Um mapa de consolidação foi construído para reduzir as variações em 11 gêneros canônicos: mpb, samba, sertanejo, forró, rock, pop, funk, hip hop, axé, gospel e reggae.

A distribuição final dos gêneros no corpus de modelagem apresentou grande desbalanceamento: mpb apareceu em 24,1% das músicas, enquanto funk representou apenas 2,0%. Gospel, sertanejo, pop e samba ficaram entre 11% e 14%, configurando um cenário multi-rótulo desafiador.

3.4. Pré-processamento Textual

O texto das letras passou pelo seguinte pipeline de limpeza:

- Conversão para letras minúsculas.
- Remoção de caracteres especiais e números (mantendo acentuação do português).
- Tokenização com o tokenizador do NLTK para português.
- Remoção de stopwords em português utilizando a lista do NLTK.
- Stemming com o algoritmo RSLP (Removedor de Sufixos da Língua Portuguesa), gerando a coluna lyric_stemmed usada pelos modelos clássicos.

Para o BERTimbau, o texto original sem stemming foi utilizado, pois o modelo aprende representações contextuais diretamente dos tokens e não se beneficia de pré-processamento agressivo.

4. Metodologia

4.1. Técnicas Utilizadas

Dois grupos de técnicas foram aplicados: modelos clássicos de aprendizado de máquina com representações Bag-of-words e de Embeddings, e um modelo de linguagem baseado em Transformers.

Regressão Logística com TF-IDF

O TF-IDF transforma cada letra em um vetor esparso ponderado pela frequência dos termos e pela raridade de cada termo no corpus. Foram utilizados até 50.000 features e n-gramas de 1 a 4 palavras para a abordagem multi-classe completa, e 5.000 features com n-gramas de 1 a 2 na abordagem Top 5. A Regressão Logística foi treinada no esquema One-vs-Rest com class_weight='balanced' para compensar o desbalanceamento entre gêneros.

Naive Bayes com TF-IDF

O Naive Bayes é um classificador probabilístico adequado para dados textuais esparsos. Foi aplicado sobre a mesma representação TF-IDF, também no esquema One-vs-Rest. Embora simples, o Naive Bayes tende a ter alta precisão em cenários desbalanceados, mas baixo recall para classes minoritárias.

Random Forest com TF-IDF

Um conjunto de 200 árvores de decisão foi treinado sobre a representação TF-IDF. O parâmetro class_weight='balanced' foi utilizado para lidar com o desbalanceamento. O Random Forest possui capacidade de capturar relações não-lineares entre os tokens, mas tende a ser mais conservador na predição, favorecendo alta precisão em detrimento do recall.

Word2Vec + Regressão Logística

Um modelo Word2Vec próprio foi treinado sobre os tokens com stemming do corpus, com vetores de 100 dimensões, janela de contexto de 5 palavras e frequência mínima de 2 ocorrências. A representação de cada música foi obtida pela média dos vetores de suas palavras (mean pooling). A Regressão Logística foi então treinada sobre esses vetores densos no esquema One-vs-Rest.

BERTimbau (fine-tuning)

Para a abordagem com os Top 5 gêneros, foi realizado o fine-tuning do BERTimbau (neuralmind/bert-base-portuguese-cased), um modelo BERT pré-treinado em textos em português. O modelo foi adaptado para classificação multi-rótulo adicionando uma camada de classificação sobre o token [CLS]. A função de perda utilizada foi BCEWithLogitsLoss com pesos positivos para compensar o desbalanceamento. O treinamento foi conduzido por 3 épocas com taxa de aprendizado de 2e-5, batch size de 32 e weight decay de 0.1. As métricas de avaliação foram F1-micro e F1-macro calculadas com threshold de 0.5.

4.2. Experimentos e Estratégia de Avaliação

O projeto foi estruturado em dois experimentos principais para avaliar o impacto do número de classes no desempenho dos modelos.

Experimento 1 – Classificação com 11 Gêneros (Notebook 1)

O primeiro experimento utilizou todos os 11 gêneros consolidados como classes-alvo. O dataset foi dividido em 80% para treino (34.900 amostras) e 20% para teste (8.726 amostras). Os quatro modelos clássicos foram avaliados utilizando as métricas de precisão, recall e F1-score (macro e weighted). A binarização multi-rótulo foi realizada com o MultiLabelBinarizer do scikit-learn. O modelo campeão deste experimento foi salvo para uso posterior.

Experimento 2 – Classificação com Top 5 Gêneros (Notebook 2)

No segundo experimento, foi realizado um treino exploratório com todos os 11 gêneros para identificar os 5 com melhor F1-score individual. O dataset foi então filtrado para manter apenas as músicas pertencentes a pelo menos um desses 5 gêneros, e os quatro modelos clássicos foram re-treinados nessa configuração simplificada. Adicionalmente, o BERTimbau foi fine-tunado nesse subconjunto, representando a abordagem mais sofisticada do projeto.

Todas as métricas reportadas foram calculadas sobre um conjunto de teste mantido fixo (random_state=42, test_size=0.2), garantindo a comparabilidade entre modelos. A métrica

principal de comparação entre abordagens foi o F1-macro, que penaliza igualmente o mau desempenho em classes menores.

5. Resultados

5.1. Experimento 1 – 11 Gêneros (Modelos Clássicos)

A Tabela 1 apresenta o desempenho comparativo dos quatro modelos clássicos treinados com todos os 11 gêneros. A Regressão Logística com TF-IDF (50k features, n-gramas 1-4) foi o modelo com melhor desempenho geral, sendo considerado o modelo campeão desta abordagem. Os valores indicados são referentes às métricas macro médias sobre o conjunto de teste.

Tabela 1 – Comparativo dos modelos clássicos (11 gêneros). * = modelo campeão.

Modelo	Precisão (Macro)	Recall (Macro)	F1 (Macro)	F1 (Weighted)
Regressão Logística (TF-IDF)	0.43	0.62	0.50	0.58
Naive Bayes (TF-IDF)	0.48	0.12	0.16	0.27
Random Forest (TF-IDF)	0.64	0.19	0.26	0.36
Word2Vec + Reg. Logística	0.28	0.72	0.37	0.48

A Tabela 2 detalha o desempenho por classe do modelo campeão (Regressão Logística com TF-IDF). Observa-se que gêneros com maior suporte e características lexicais mais distintas, como gospel e mpb, obtiveram os melhores F1-scores. Gêneros culturalmente sobrepostos ou com menor representação, como axe, funk e reggae, apresentaram desempenho inferior.

Tabela 2 – Desempenho por classe: Regressão Logística TF-IDF (11 gêneros).

Gênero	Precisão	Recall	F1-Score	Suporte
axe	0.24	0.54	0.33	412
forro	0.34	0.59	0.43	675
funk	0.24	0.45	0.32	239
gospel	0.87	0.90	0.88	1451
hip hop	0.61	0.72	0.66	486
mpb	0.65	0.76	0.70	3066
pop	0.30	0.46	0.36	1521
reggae	0.25	0.40	0.31	266

Gênero	Precisão	Recall	F1-Score	Suporte
rock	0.35	0.58	0.44	1233
samba	0.41	0.65	0.50	1509
sertanejo	0.52	0.76	0.62	1645

5.2. Experimento 2 – Top 5 Gêneros (Modelos Clássicos + BERT)

A partir dos resultados do Experimento 1, foram identificados os 5 gêneros com melhor F1-score individual: gospel, mpb, sertanejo, hip hop e samba. O dataset filtrado conteve apenas as músicas pertencentes a ao menos um desses gêneros, totalizando 40.779 amostras (treino: 32.623 | teste: 8.156).

A Tabela 3 apresenta o desempenho dos modelos clássicos e do BERTimbau na configuração Top 5. A Tabela 4 detalha as métricas de precisão e F1 por gênero para cada modelo.

Tabela 3 – Desempenho dos modelos na configuração Top 5 gêneros.

Modelo	Precisão (Macro)	Recall (Macro)	F1-Macro	F1-Micro
Regressão Logística (TF-IDF)*	0.62	0.80	0.69	0.71
Naive Bayes (TF-IDF)	0.82	0.49	0.58	0.64
Random Forest (TF-IDF)	0.85	0.50	0.60	0.66
Word2Vec + Reg. Logística	0.51	0.79	0.59	0.61
BERTimbau (fine-tuning)*	—	—	0.779	0.766

Tabela 4 – Precisão e F1 por gênero nos quatro modelos clássicos (Top 5). P = Precisão.

Gênero	LR P	LR F1	NB P	NB F1	RF P	RF F1	W2V F1
gospel	0.91	0.91	0.96	0.88	0.96	0.90	0.89
mpb	0.73	0.77	0.71	0.72	0.78	0.75	0.71
sertanejo	0.57	0.66	0.72	0.54	0.84	0.50	0.58
hip hop	0.45	0.57	0.98	0.48	0.99	0.55	0.30
samba	0.43	0.54	0.73	0.27	0.68	0.32	0.49

A Regressão Logística com TF-IDF foi o modelo com melhor equilíbrio entre precisão e recall (F1-Macro 0.69), sendo o campeão desta abordagem. Gospel obteve F1 de 0.91, a melhor performance individual; samba foi o gênero mais difícil, com F1 de 0.54, refletindo sua sobreposição vocabular com mpb e pagode. O Naive Bayes alcançou precisão macro elevada (0.82) mas recall baixo (0.49), repetindo o padrão do Experimento 1. O Random Forest apresentou precisão macro ainda maior (0.85) mas recall igualmente limitado (0.50), com hip hop chegando a 0.99 de precisão e apenas 0.38 de recall — evidenciando o comportamento conservador da floresta. O Word2Vec obteve recall elevado (0.79) mas precisão baixa (0.51), especialmente fraco em hip hop (F1 0.30), provavelmente porque embeddings de média diluem o vocabulário característico desse gênero.

O BERTimbau foi fine-tunado por aproximadamente 1.72 épocas (1.500 steps) com avaliação a cada 100 steps. O melhor checkpoint foi salvo automaticamente com base no F1-Macro de validação. A Tabela 5 apresenta a evolução completa das métricas durante o treinamento.

Tabela 5 – Evolução do treinamento do BERTimbau (Top 5 gêneros). Melhor checkpoint destacado em verde.

Step	Train Loss	Val Loss	F1-Micro	F1-Macro
100	0.7656	0.6923	0.6126	0.6399
200	0.6075	0.6090	0.6689	0.6805
300	0.5631	0.5713	0.6987	0.7232
400	0.5614	0.5406	0.7081	0.7228
500	0.5388	0.5213	0.7134	0.6959
600	0.5207	0.4916	0.7360	0.7437
700	0.4911	0.5006	0.7367	0.7296
800	0.4830	0.4921	0.7409	0.7606
900	0.4554	0.4660	0.7348	0.7505
1000	0.4348	0.4880	0.7403	0.7359
1100	0.4201	0.4578	0.7604	0.7743
1200 (melhor)	**0.3816**	**0.4613**	**0.7657**	**0.7790**
1300	0.3912	0.4635	0.7541	0.7697
1400	0.4029	0.4633	0.7341	0.7356
1500	0.3692	0.4635	0.7540	0.7355

O melhor resultado foi obtido no step 1200, com F1-Micro de 0.7657 e F1-Macro de 0.7790. O modelo apresentou convergência consistente da loss de treino (de 0.766 até 0.369), enquanto a loss de validação estabilizou em torno de 0.46 a partir do step 800, indicando boa generalização sem overfitting severo. Após o step 1200, as métricas de validação oscilaram sem melhoria, sugerindo que o modelo atingiu seu ponto ótimo antes de completar as 3 épocas planejadas.

5.3. Comparação entre as Duas Abordagens

A Tabela 5 resume a comparação entre as melhores configurações das duas abordagens, usando a Regressão Logística com TF-IDF como modelo de referência.

*Tabela 6 – Comparativo entre as abordagens (melhor modelo de cada). * = melhor geral.*

Abordagem / Modelo	Precisão (Macro)	Recall (Macro)	F1 (Macro)	F1 (Micro)
NB1 – LR TF-IDF (11 classes)	0.43	0.62	0.50	0.47
NB2 – LR TF-IDF (Top 5)	0.62	0.80	0.69	0.71
NB2 – BERTimbau (Top 5)*	—	—	0.779	0.766

A redução de 11 para 5 classes trouxe ganhos expressivos e consistentes. O F1-Macro da Regressão Logística com TF-IDF subiu de 0.50 para 0.69 (+38%), e o recall macro passou de 0.62 para 0.80. Isso se explica por dois fatores: menor sobreposição semântica entre os 5 gêneros selecionados (gospel, mpb, sertanejo, hip hop e samba possuem vocabulários mais distintos entre si do que o conjunto original de 11), e menor complexidade do problema multi-rótulo — com menos classes, o classificador One-vs-Rest constrói fronteiras de decisão mais robustas.

O ganho mais expressivo veio do BERTimbau, que atingiu F1-Macro de 0.779 e F1-Micro de 0.766 no seu melhor checkpoint (step 1200), superando em 11 pontos percentuais a Regressão Logística com TF-IDF (F1-Macro 0.69). O modelo pré-treinado em português captura nuances semânticas e contextuais das letras que escapam às representações bag-of-words (TF-IDF) e mesmo aos embeddings estáticos (Word2Vec). O uso de pesos positivos na função de perda (pos_weight) foi fundamental para que o BERT não ignorasse os gêneros menos frequentes.

Entre os modelos clássicos, a Regressão Logística com TF-IDF manteve-se como o melhor algoritmo nas duas abordagens. O Naive Bayes mostrou-se inadequado para o cenário multi-rótulo desbalanceado, com recall macro de apenas 0.49 no Top 5 — o modelo é

muito conservador e deixa de classificar corretamente gêneros menos frequentes como samba (F1 0.27) e hip hop (F1 0.48). O Random Forest apresentou a maior precisão macro (0.85), mas com recall de 0.50 evidenciou o mesmo viés conservador. O Word2Vec, embora tenha obtido recall elevado (0.79), apresentou precisão baixa (0.51) e foi particularmente fraco em hip hop, gênero em que o vocabulário específico se dilui na operação de média dos vetores.